

IA Sesgos Falacias

Detección de sesgos y falacias en textos con IA

Introducción

Proyecto para diseñar una IA que identifica sesgos cognitivos y falacias argumentativas, mejorando la calidad del discurso.

Proyecto de IA para detección de sesgos y falacias

Descripción del proyecto y objetivos

La IA busca detectar y clasificar sesgos cognitivos y falacias en textos y diálogos, facilitando análisis crítico y transparente.

Investigación realizada y hallazgos clave

Análisis de literatura y proyectos como IBM AI Fairness 360 y YesChat. Se destaca la dificultad en falacias implícitas y sesgos por datos sesgados.

Referentes y proyectos similares existentes

Se incluyen proyectos como YesChat basado en BERT para detección de falacias y estudios sobre sesgos en IA conversacional y reclutamiento.



Principales desafíos técnicos y éticos

Desafíos incluyen ambigüedad cultural, coste computacional, necesidad de auditorías éticas y evitar discriminación en IA.

Referentes y proyectos similares existentes

Proyectos relevantes incluyen IBM AI Fairness 360 para medición de sesgos, YesChat que detecta falacias con BERT, y casos como el algoritmo de reclutamiento de Amazon que mostró sesgo de género. También destacan estudios sobre sesgos en publicidad y reconocimiento facial que evidencian impacto social y técnico.

Principales desafíos técnicos y éticos

Los retos incluyen la ambigüedad cultural, costo computacional, necesidad de auditoría ética y evitar discriminación inherente en datos y algoritmos. Se requiere transparencia, supervisión multidisciplinar y adaptación constante para mitigar sesgos.

Conclusiones

La detección de sesgos y falacias con IA es un campo en evolución. Éxito depende de datos representativos, auditoría humana, modelos contextuales y marcos éticos claros. La innovación responsable requiere equilibrio entre avance técnico, regulación y participación social para sistemas justos y transparentes.

