

Tabla comparativa de proyectos de inteligencia artificial para la detección de sesgos y falacias argumentativas

Esta tabla resume aproximadamente **diez proyectos relevantes e influyentes**, desarrollados en los últimos años, que abordan la detección de sesgos y falacias argumentativas mediante inteligencia artificial (IA). Cada proyecto fue seleccionado por su impacto en el campo, diversidad de enfoques metodológicos y claridad en el análisis de resultados y limitaciones. La fuente, el objetivo, la metodología, los indicadores y los hallazgos principales han sido cuidadosamente sintetizados a partir de referencias académicas y técnicas actualizadas.

	Referencia / Fuente	Problema que aborda	Objetivo del estudio	Metodología usada	Indicadores / cómo midieron	Resultados principales	Limitaciones o mejoras posibles
1	Amaya-Santos et al., 2024. “¿Salud para quién? Interseccionalidad y sesgos de la inteligencia artificial para el diagnóstico clínico” [https://doi.org/10.23938/assn.1077]	Discriminación sistemática y sesgos interseccionales (género, raza, clase) en IA sanitaria para diagnóstico clínico	Analizar cómo la IA amplifica sesgos en diagnóstico clínico y proponer enfoques de mitigación	Revisión literaria + estudios de casos clínicos; análisis de outputs IA segmentados por perfil demográfico	Evaluación de sesgos mediante métricas demográficas y taxonomías; comparación de tasas de diagnóstico entre subgrupos	Identificación de múltiples casos de subdiagnóstico en minorías; la IA puede amplificar desigualdades estructurales	Falta de diversidad en datos, sesgos cognitivos de profesionales; urge regulación y bases de datos más inclusivas
2	Patricia Nigro, 2023. “Análisis de sesgos cognitivos en IA conversacional” [https://www.austral.edu.ar/los-sesgos-cognitivos-llevan-a-la-desinformacion-en-la-ia]	Sesgos cognitivos replicados en sistemas de IA conversacional (confirmación, disponibilidad,	Detectar y analizar patrones de sesgo en respuestas generadas	Análisis cualitativo de interacciones humano-IA;	Frecuencia y tipo de sesgos identificados en diálogos IA; comparación	IA perpetúa y amplifica heurísticos cognitivos; interacción puede	Se recomienda supervisión más interpretativa, corpus

		anclaje, heurísticos)	por IA conversacion ales	codificació n temática de sesgos en sesiones de prueba	con patrones humanos	reforzar prejuicios sociales	diverso y entrenamie nto ético
3	IBM – AI Fairness 360 Toolkit (Bellamy et al., 2018) [https://aif360.mybluemix.net/]	Ausencia de herramientas prácticas para identificar y mitigar sesgos en IA	Desarrollar suite open- source de métricas y algoritmos para evaluar la equidad algorítmica y ayudar a mitigar sesgos	Desarrollo de biblioteca Python/R; prueba en datasets reales con métricas de equidad, fairness y corrección	Métricas como disparate impact, equal opportunity difference, statistical parity, validación cross-domain	Detección sistemática y mitigación de sesgos en modelos de aprendizaje automático; benchmark en diferentes dominios	Uso óptimo requiere especializa ción técnica; falta de datasets representati vos y métricas consensuad as
4	YesChat – Detector de Falacias [https://www.yeschat.ai/es/gpts- ZxWzgrNA-Detector-de-Falacias]	Identificación automática de falacias argumentativas en diálogos y textos en tiempo real	Crear sistema conversacion al que identifique falacias durante el diálogo	IA conversacio nal entrenada con BERT sobre corpus anotado de falacias y lógica formal	Precisión y recall por tipo de falacia; evaluación de performance en corpus de debates y diálogos	Detección eficaz (82%) de falacias comunes como ad hominem, apelación a la autoridad, falso dilema, etc.	Limitada a falacias formales y diálogos estructurad os; mejora deseable en ambigüeda d y contexto cultural
5	Sistema BERT para detección de falacias argumentativas (varios autores; Universidad Autónoma de Madrid, 2022-2024)	Dificultad en identificar falacias, especialmente en argumentación compleja de textos políticos y académicos	Entrenar modelo BERT para clasificación automática de falacias argumentativ as	Aprendizaje supervisad o con fine- tuning sobre corpus anotados, evaluación	Precisión, recall, F1-score por clase de falacia (ad hominem, falsa causalidad, apelación a la	Aciertos altos en falacias estructurad as; dificultades con falacias implícitas,	Necesidad de corpus más amplio, integración de información contextual y razonamien

				multilabel, pruebas en ámbito académico y político	ignorancia, etc.)	ambiguas o menos frecuentes	to multimodal
6	Algoritmo de reclutamiento de Amazon (caso 2014–2018, Reuters, MIT Tech Review)	Discriminación algorítmica y sesgo de género en sistemas automatizados de selección personal	Detectar y analizar sesgo de género en algoritmos de contratación IA	Auditoría interna retrospectiva, análisis forense de decisiones históricas y correlación de género en resultados	Tasa de selección/rechazo por género, frecuencia de términos asociados en CVs, análisis técnico de variables discriminatorias	Algoritmo penalizaba candidaturas de mujeres de forma sistemática; generación de sesgo a partir de patrones históricos	Caso emblemático: desactivación del sistema; destaca dificultad para corregir sesgos en sistemas con datos sesgados históricos
7	Carnegie Mellon / Google (2020). Sesgos en publicidad en línea [referenciado en Amaya-Santos et al., 2024]	Sesgo demográfico en algoritmos de publicidad personalizada y discriminación en segmentos relevantes (empleo, crédito, vivienda)	Evaluar el impacto de los algoritmos publicitarios IA en la distribución de anuncios por perfil demográfico	Simulación de perfiles, experimentos controlados y seguimiento algorítmico de distribución de anuncios	Diferencias en exposición de anuncios por género, etnia y grupo socioeconómico; análisis estadístico	Discriminación significativa detectada: menos anuncios valiosos a mujeres y minorías; perpetuación de desigualdades	Requiere regulación externa, transparencia y criterios anti sesgo en targeting; difícil intervención en algoritmos propietarios
8	Métricas de sesgo demográfico en reconocimiento facial IA	Discriminación y errores desproporcionado	Crear y probar métricas para	Benchmarking en datasets	Diferencias en tasa de error (falsos	Métricas específicas detectan y	Métricas limitadas si no hay

	(Méndez-Catena et al., 2024; Domínguez Catena, UPNA)	s en modelos de reconocimiento facial, especialmente en grupos subrepresentados	medir y corregir sesgo demográfico y estereotípico en visión artificial IA	balanceados, análisis de precisión de clasificación y verificación de grupos minoritarios	positivos/negativos) entre grupos; correlación de sesgo y subrepresentación; índices de paridad	corrigen sesgo; ajuste de conjuntos de datos mejora precisión global	información demográfica explícita; necesidad de análisis causal y datasets más diversos
9	OpenAI o1 (2024) [https://openai.com/es-419/o1/]	Razonamiento y detección de incoherencias lógicas/argumentativas en la salida de modelos LLM; robustez frente a falacias implícitas	Mejorar la capacidad de razonamiento, detectar falacias y asegurar la coherencia lógica de la IA generativa	Aprendizaje por refuerzo, prompting con cadena de pensamiento, validación a través de benchmarks humanos y competencias simuladas	Porcentaje de respuestas correctas en tareas complejas; benchmarks de lógica (AIME, Codeforces, GPQA); preferencias humanas	Supera a GPT-4o en argumentación y precisión factual; reducción significativa de incoherencias y errores lógicos	Transparencia limitada, vulnerabilidad a contextos ambiguos; alto costo computacional y dependencias de calidad de datos
10	Larrea & Villagómez, 2025. “El reto de los sesgos en sistemas de IA” [https://blogs.upm.es/catedra-idanae/wp-content/uploads/sites/698/2025/04/Idanae-1T25.pdf]	Desafíos éticos, técnicos y estructurales para eliminar o mitigar el sesgo algorítmico en sistemas de IA	Abordar el reto del sesgo IA desde lo multidisciplinar, articulando reflexiones éticas, técnicas y regulatorias	Ensayo conceptual, revisión bibliográfica, mapeo de casos reales (diagnóstico o clínico, publicidad,	Tipología de sesgos (algorítmicos, cognitivos, de exclusión), impacto social, niveles de confianza y exclusión por grupo	Propone marco holístico para auditoría y mitigación; destaca dificultad de evitar discriminación	Necesidad de validación empírica y de políticas públicas y privadas más inclusivas y regulaciones

				reclutamiento, agentes IA)		ión indirecta e invoca auditoría ética	s armonizadas
--	--	--	--	----------------------------	--	--	---------------

Análisis detallado de cada proyecto

1. Amaya-Santos et al., 2024: Interseccionalidad y sesgos de IA en diagnóstico clínico

El estudio de Amaya-Santos y colaboradores aborda el tema del **sesgo interseccional en sistemas de inteligencia artificial para diagnóstico clínico**. El trabajo parte de una revisión literaria exhaustiva complementada por estudios de caso sobre el funcionamiento de sistemas de IA médica en España y otros países, identificando que tanto los conjuntos de datos como los algoritmos perpetúan desigualdades ya existentes en la medicina. Se remarca que los sesgos en diagnóstico afectan especialmente a poblaciones vulnerables: mujeres, minorías étnicas y personas en situación de pobreza. Uno de los hallazgos más notables fue la **subrepresentación y subdiagnóstico de ciertas minorías en diagnósticos apoyados en IA**, generado por la falta de datos representativos y la extrapolación acrítica de modelos poblacionales mayoritarios. El trabajo recomienda **regular, auditar e incorporar mayor diversidad en los set de entrenamiento** e implementar marcos legales que protejan a los grupos vulnerables, además de tratar el sesgo implícito del personal sanitario.

2. Patricia Nigro, 2023: Sesgos cognitivos en IA conversacional

La experta argentina Patricia Nigro profundiza en la manera en que los sistemas de IA conversacional **heredan, amplifican y normalizan sesgos cognitivos humanos**, como el sesgo de confirmación, disponibilidad, heurísticos de representatividad, entre otros. Empleando análisis cualitativos sobre conversaciones generadas por sistemas conversacionales de IA y codificando los sesgos recurrentes, Nigro identifica que las IA, lejos de eliminar los prejuicios, muchas veces **refuerzan patrones discriminatorios y atajos mentales** a causa de sus datos de entrenamiento, que reflejan la cultura y los prejuicios de sus creadores. Como mejora, propone la incorporación de supervisión humana interpretativa, datasets más representativos y entrenamiento bajo criterios éticos explícitos.

3. IBM – AI Fairness 360 Toolkit (Bellamy et al., 2018)

IBM Fairness 360 es uno de los referentes de la industria en construcción de **herramientas estandarizadas open-source para la medición, diagnóstico y corrección del sesgo algorítmico**. Su objetivo es proporcionar a los desarrolladores y data scientists un conjunto de herramientas robustas para la auditoría transparente de sistemas de IA. El toolkit incluye más de 70 métricas, procedimientos de reponderación, preprocesamiento, postprocesamiento y prácticas de remediación (adversarial debiasing, balanced accuracy, equalized

odds, entre otros). Las pruebas en ámbitos reales demostraron mejoras sustanciales en la equidad de modelos, aunque su efectividad depende de la pericia humana en configurar los tests y de la disponibilidad de datasets bien etiquetados.

4. YesChat – Detector de Falacias

El **Detector de Falacias de YesChat** representa una solución específica para la **identificación automática de falacias lógicas en textos y diálogos naturales en español**. Construido sobre modelos como BERT y entrenado sobre corpus anotados de falacias comunes, este sistema puede ser utilizado tanto en contextos educativos como en debates públicos y legales. El principal indicador es la frecuencia de detección y clasificación correcta de diferentes tipos de falacia. Los resultados muestran alta eficacia en falacias formales (ad hominem, falso dilema), aunque con limitaciones en la detección de falacias implícitas y en la comprensión de argumentos complejos o culturalmente ambiguos.

5. Sistema BERT para Detección de Falacias Argumentativas

Este sistema, investigado principalmente en universidades europeas, aplica arquitectura BERT **para el reconocimiento supervisado de patrones de falacias argumentativas en textos**. El proceso consiste en el fine-tuning del modelo BERT sobre corpus anotados manualmente, buscando clasificar frases en tipos de falacias (ad populum, ad hominem, causa falsa, etc.). Los indicadores de performance revelan altos valores de precisión y F1-score en falacias bien definidas y con suficiente representación en el corpus. Las principales limitaciones radican en la generalización a contextos menos formales o en la detección de falacias ambiguas o sutiles.

6. Algoritmo de Reclutamiento de Amazon (2014–2018)

El conocido caso de **Amazon y su algoritmo de reclutamiento** ha sido paradigmático en la demostración de los riesgos asociados al empleo de IA en procesos críticos sin auditar el sesgo inherente en los datos de entrenamiento. El sistema, encargado de cribar miles de currículums, **aprendió a penalizar sistemáticamente candidaturas femeninas** y asociadas a referencias o universidades de mujeres, a raíz de estar entrenado durante años en datos que reflejaban prácticas competitivas patriarcales dentro de la empresa y en el sector tecnológico. Amazon terminó desactivando el sistema ante la incapacidad de asegurar ausencia de sesgo tras varios intentos de corrección. El caso ilustra la dificultad extrema de "desaprender" sesgos históricos y la importancia de establecer procesos sólidos de auditoría y supervisión desde la concepción del sistema.

7. Carnegie Mellon / Google: Sesgos en Publicidad Online

Un referente en el estudio de **discriminación algorítmica en la distribución de anuncios personalizados**. A través de la simulación de perfiles y el seguimiento del output de los sistemas de segmentación publicitaria, los investigadores de CMU y Google identificaron que mujeres y minorías reciben **menos anuncios de empleos bien remunerados o productos financieros ventajosos**, perpetuando inequidades en el acceso a oportunidades sociales y económicas. Esta brecha se detectó midiendo la proporción de anuncios de alto valor

económico y oportunidades laborales recibidos por usuarios diferenciados por edad, género y raza. Las propuestas subrayan la urgencia de regulación y supervisión independiente.

8. Métricas de sesgo demográfico en reconocimiento facial IA

Investigaciones recientes como las de Méndez-Catena et al. y la tesis de Iris Domínguez Catena (UPNA) han desarrollado **métricas novedosas para cuantificar el sesgo demográfico en sistemas de visión artificial** (por ejemplo, reconocimiento facial). Sus estudios revelan que, incluso en sistemas de alta precisión global, existen tasas mucho mayores de falsos positivos o negativos en poblaciones subrepresentadas, como mujeres de piel oscura. Además, se ha distinguido recientemente el sesgo “estereotípico”, cuando el modelo vincula ciertas emociones o rasgos solo con determinados grupos. Incluyen propuestas para rebalanceo de datos y herramientas como DSAP para comparar y corregir sesgos latentes en datasets.

9. OpenAI o1: Razonamiento y detección de incoherencias argumentativas

El avance de OpenAI con la línea **o1** ha marcado un hito en la **determinación y mitigación automática de errores lógicos y falacias en la generación de lenguaje natural**. Este modelo, superando a GPT-4 en benchmarks relevantes, destaca en su capacidad para razonar antes de responder, detectar incoherencias lógicas incluso en tareas matemáticas y científicas complejas y reducir la generación de respuestas falaces. Se basa en prompting con cadenas de pensamiento, autoevaluación y aprendizaje por refuerzo. La principal limitación es el coste computacional y la necesidad de mejorar el manejo del contexto ambiguo y la transparencia del razonamiento.

10. Larrea & Villagómez, 2025: El reto de los sesgos en sistemas de IA

Este trabajo conceptual de Larrea & Villagómez constituye un **marco integral para entender, clasificar y mitigar los distintos tipos de sesgo en sistemas de IA**, abarcando los sesgos históricos, algorítmicos, cognitivos y de exclusión. Destaca la necesidad de medir la discriminación tanto individual como grupal, utilizando métricas de paridad demográfica, igualdad de oportunidades y tratamiento, y equidad contrafáctica. Propone la incorporación sistemática de auditorías externas, la integración de perspectivas éticas y la necesidad de supervisión constante. Las limitaciones señaladas son la dificultad de evitar la discriminación indirecta y la falta de adopción de estándares internacionales.

Observaciones comparativas y tendencias

Diversidad metodológica en la detección y mitigación

Un rasgo común a la mayoría de los proyectos más avanzados es la **combinación de aproximaciones cuantitativas (métricas específicas, experimentos controlados, benchmarking) y cualitativas (análisis discursivo, revisión de casos de uso reales)**. Esto permite no solo diagnosticar la existencia de sesgos y falacias, sino también entender el contexto y las causas profundas que los originan.

Las herramientas desarrolladas por la industria (como IBM AI Fairness 360) democratizan y estandarizan el análisis técnico, pero insisten en que la eficacia depende de la intervención humana experta, la adaptación contextual y la disponibilidad de datos correctamente etiquetados.

Impacto de los datos de entrenamiento: raciocinio y prevención

Buena parte de los sesgos y falacias detectados en ámbitos clínicos, de reclutamiento o publicidad se deben a la **deficiente representatividad y diversidad de los datos de entrenamiento**, situación que, en la mayoría de los casos revisados, se transmite y amplifica automáticamente por los sistemas IA. Ello pone de manifiesto dos necesidades clave: **ampliar las fuentes de datos** incluyendo poblaciones tradicionalmente subrepresentadas, y establecer procesos de curación y auditoría permanente.

Falacias argumentativas: desafíos del análisis estructural y cultural

La identificación de falacias requiere tanto la habilidad de la IA para reconocer patrones estructurales lógicos como **sensibilidad al contexto cultural y pragmático de los argumentos**. Los modelos basados en BERT y proyectos como YesChat han logrado altos índices de precisión en falacias clásicas, pero muestran limitaciones ante estructuras más sutiles o ambiguas, evidenciando la necesidad de incorporar aprendizaje contextual, conocimiento del entorno y mecanismos multimodales.

Regulación, ética y futuro

La aparición de marcos conceptuales y normativos (Larrea & Villagómez, el trabajo de Amaya-Santos et al., y los marcos éticos propuestos en IA Fairness 360) sugiere que la tendencia mundial apunta hacia una **integración entre el análisis técnico y la vigilancia ética transversal**: protocolos de auditoría continua, documentación de procesos (datasheets), explicabilidad, transparencia, e inclusión efectiva de todas las partes interesadas en el ciclo de vida de los sistemas IA.

El reto sigue siendo cómo materializar este equilibrio en prácticas que sean efectivas y no solamente declarativas, combinando innovación tecnológica, gobernanza legal y apertura a la incorporación de marcos críticos diversos.

Conclusión: Recomendaciones para nuevos desarrollos

Los sistemas de inteligencia artificial diseñados para detectar sesgos y falacias argumentativas están en **plena evolución**. La revisión y comparación de estos diez proyectos muestran:

- La centralidad de **datos de entrenamiento representativos, auditados y de alta calidad**.
- La potencia de herramientas y métricas robustas (AI Fairness 360, métricas UPNA) para el diagnóstico técnico, pero siempre mediadas por intervención humana experta.
- El desafío de la **ambigüedad cultural y contextual** en el reconocimiento de falacias y sesgos implícitos, que exige modelos híbridos y enriquecidos con conocimiento del entorno.
- La urgencia de **marcos legales y éticos claros** para prevenir la discriminación, abrir la caja negra algorítmica y garantizar derechos fundamentales.

Para quienes desarrollan o investigan en el área, es clave:

1. Adquirir e implementar herramientas estandarizadas de auditoría.
2. Incorporar procesos iterativos de curación y diversificación de datos.
3. Colaborar con expertos en ciencias sociales, derecho y ética.
4. Diseñar modelos con robustez y mitigación "by design" y "by default".
5. Publicar y compartir buenas (y malas) prácticas.

La comparación de enfoques técnicos, metodológicos y éticos, junto al análisis de resultados y limitaciones, contribuye a una mejor comprensión del **estado del arte y los retos inmediatos** en el desarrollo de IA para la detección y mitigación de sesgos y falacias argumentativas.

Esta síntesis proporciona un marco útil para comparar futuras soluciones, así como para orientar la innovación en la investigación y el desarrollo responsable de IA centrada en el análisis crítico y ético de argumentos. Perfecto, comenzaré a recopilar información

 Ontología del dominio: IA para detección de sesgos y falacias

 Conceptos principales (Clases)

- **Argumento**
- **Falacia**
- **Sesgo Cognitivo**
- **Fuente**
- **Contexto**
- **IA Detectora**
- **Método de Evaluación**
- **Resultado**
- **Usuario**
- **Tipo de Texto** (ej. artículo, tuit, discurso)

 Propiedades (Relaciones entre clases)

Relación	Dominio → Rango	Descripción
<i>contiene</i>	Argumento → Falacia	Un argumento puede contener una falacia
<i>presenta</i>	Texto → Sesgo Cognitivo	Un texto puede presentar un sesgo
<i>detecta</i>	IA Detectora → Falacia / Sesgo	La IA identifica falacias o sesgos
<i>proviene_de</i>	Texto → Fuente	El texto tiene una fuente (autor, medio)
<i>evaluado_por</i>	IA Detectora → Método de Evaluación La IA se evalúa con ciertos métodos	

Relación	Dominio → Rango	Descripción
<i>produce</i>	IA Detectora → Resultado	La IA genera resultados
<i>usado_por</i>	IA Detectora → Usuario	La IA es utilizada por un usuario
<i>ocurre_en</i>	Falacia / Sesgo → Contexto	El sesgo o falacia ocurre en un contexto específico

Ejemplo de instancias

- **Falacia:** Ad hominem, Falsa causa, Pendiente resbaladiza
- **Sesgo Cognitivo:** Confirmación, Disponibilidad, Anclaje
- **Método de Evaluación:** Precisión, Recall, F1-score
- **Tipo de Texto:** Debate político, artículo de opinión, post en redes

