

Modelo simbólico para detección de sesgos y falacias argumentativas

(Generado automáticamente)

18 de noviembre de 2025

Resumen

Documento con el modelo matemático que formaliza la detección de falacias y sesgos argumentativos. Integra la ontología y axiomas provistos, combina reglas simbólicas, modelos probabilísticos, y técnicas de propagación en grafos; incluye funciones de costo/ganancia y una estrategia de control para asignación de recursos computacionales.

Índice

1. Notación, conjuntos y parámetros	2
1.1. Conjuntos principales	2
1.2. Parámetros y funciones conocidas	2
2. Axiomas formales (versión simbólica)	3
3. Modelos probabilísticos por argumento	3
3.1. Modelo discriminativo (clasificador)	4
3.2. Componente basado en reglas (simbólico)	4
3.3. Componente de grafo / propagación	4
3.4. Combinación en un score final	4
4. Incorporación de la confiabilidad de evidencia y fuente	5
5. Decisión y umbrales óptimos	5
6. Entrenamiento: función de pérdida y regularización	5
7. Regularización simbólica: honrar axiomas	6
8. Modelo de propagación en grafo (detalles)	6
9. Control de recursos: selección de métodos bajo presupuesto	6
10. Métricas de evaluación	7

11.Tratamiento de premisas implícitas	7
12.Ejemplo resumido del pipeline de inferencia (en forma matemática)	7
13.Integración con axiomas lógicos (SWRL / penalizaciones)	7
14.Resumen de parámetros a estimar y datos necesarios	8
15.Notas prácticas y recomendaciones	8
16.Conclusión	8

1. Notación, conjuntos y parámetros

1.1. Conjuntos principales

- $\mathcal{T}$: conjunto de *Textos* (documentos, tweets, párrafos). Elementos $t \in \mathcal{T}$.
- $\mathcal{A}$: conjunto de *Argumentos* extraídos. Elementos $a \in \mathcal{A}$.
- $\mathcal{P}$: conjunto de *Premisas*. Elementos $p \in \mathcal{P}$.
- $\mathcal{F}$: conjunto finito de *tipos de falacia* (ej.: AdHominem, FalsaCausa, GeneralizacionA-presurada, etc.). Elementos $f \in \mathcal{F}$.
- $\mathcal{S}$: conjunto finito de *tipos de sesgo cognitivo* (ej.: ConfirmationBias, Anchoring, Availability, ...). Elementos $s \in \mathcal{S}$.
- $\mathcal{E}$: conjunto de *Evidencias* observadas (citats, datos, enlaces). Elementos $e \in \mathcal{E}$.
- $\mathcal{U}$: conjunto de *Fuentes/Usuarios*. Elementos $u \in \mathcal{U}$.
- $\mathcal{C}$: conjunto de *Contextos* (temporal, geográfico, dominio).

1.2. Parámetros y funciones conocidas

- $\text{cred} : \mathcal{U} \rightarrow [0, 1]$: credibilidad estimada de la fuente/usuario u (axioma: mayor credibilidad $\Rightarrow$ mayor peso de la evidencia).
- $\text{rel}_e \in [0, 1]$: fiabilidad (reliability) de la evidencia $e \in \mathcal{E}$ (puede depender de tipo, formato y fuente).
- $\phi(a) \in \mathbb{R}^d$: vector de características (features) extraídas del argumento a (sintácticas, semánticas, pragmáticas, de proveniencia).
- $\psi(p) \in \mathbb{R}^{d_p}$: vector de características de una premisa p .
- π_f : prior (probabilidad a priori) de que un argumento cualquiera esté asociado a la falacia f . $\pi_f \in (0, 1)$.
- $C_{\text{FP},f}, C_{\text{FN},f} \geq 0$: costos asociados a falso positivo y falso negativo para tipo de falacia f (importante para decisiones óptimas).
- B : presupuesto computacional disponible (por unidad de tiempo) para ejecutar detectores caros.
- $\text{cost}_m \geq 0$: coste computacional del método m (reglas, ML, análisis semántico profundo, etc.).
- λ parámetros de regularización o pesos de combinación que aparecen más adelante.

2. Axiomas formales (versión simbólica)

Estos axiomas formalizan reglas de integridad y supuestos del dominio (derivados de tu ontología):

1. **Axioma de composición:** todo texto contiene cero o más argumentos:

$$\forall t \in \mathcal{T}, \quad \text{Args}(t) \subseteq \mathcal{A}.$$

2. **Axioma de estructura de argumento:** cada argumento a está formado por un conjunto de premisas y una conclusión:

$$\forall a \in \mathcal{A}, \quad a = (\text{Prem}(a), \text{Conc}(a)), \quad \text{Prem}(a) \subseteq \mathcal{P}.$$

3. **Axioma de evidencia:** cada premisa p puede estar (o no) sustentada por evidencias $E_p \subseteq \mathcal{E}$ y fuentes $U_p \subseteq \mathcal{U}$:

$$\forall p \in \mathcal{P}, \quad E_p \subseteq \mathcal{E}, \quad U_p \subseteq \mathcal{U}.$$

4. **Axioma de propagación de confianza:** la confianza en la evidencia se combina multiplicativamente con la credibilidad de la fuente:

$$w_e = \text{rel}_e \cdot \text{cred}(u_e), \quad \text{para } e \text{ proveniente de } u_e.$$

5. **Axioma de exclusividad para tipos mutuamente excluyentes:** si f_1 y f_2 son excluyentes por definición, entonces no pueden ser verdaderas simultáneamente en el mismo a :

$$\forall a : \neg (F_{f_1}(a) \wedge F_{f_2}(a)).$$

6. **Axioma de detección:** la presencia de una falacia f en a implica que existe evidencia (posiblemente implícita) que activa patrones P_f :

$$F_f(a) \Rightarrow \exists p \in \text{Prem}(a) \text{ tal que } \text{pattern}_f(p) = 1.$$

3. Modelos probabilísticos por argumento

Para cada argumento $a \in \mathcal{A}$ y cada tipo de falacia $f \in \mathcal{F}$ definimos una variable aleatoria binaria:

$$Y_{a,f} = \begin{cases} 1 & \text{si el argumento } a \text{ contiene la falacia } f, \\ 0 & \text{si no.} \end{cases}$$

Queremos estimar la probabilidad posterior

$$\Pr(Y_{a,f} = 1 \mid \mathcal{O}_a),$$

donde $\mathcal{O}_a$ son las observaciones asociadas a a (features $\phi(a)$, evidencias $E_{\text{Prem}(a)}$, credibilidad de fuentes, contexto $\mathcal{C}$, etc.).

3.1. Modelo discriminativo (clasificador)

Usamos un modelo logístico (o cualquier clasificador probabilístico) para cada tipo de falacia f :

$$s_f^{\text{ML}}(a) = \sigma(\theta_f^\top \phi(a)) \quad \text{con} \quad \sigma(x) = \frac{1}{1 + e^{-x}},$$

donde $\theta_f \in \mathbb{R}^d$ son parámetros a entrenar. Entonces

$$\Pr(Y_{a,f} = 1 \mid \phi(a)) \approx s_f^{\text{ML}}(a).$$

3.2. Componente basado en reglas (simbólico)

Para cada falacia f definimos un conjunto de reglas $R_f = \{r_{f,k}\}_{k=1}^{K_f}$. Cada regla $r_{f,k}(a)$ devuelve una puntuación numérica en $[0, 1]$ (por ejemplo, por coincidencia de patrón, análisis sintáctico, detección de palabras clave, estructura lógica):

$$r_{f,k}(a) = \text{score}_{f,k}(a) \in [0, 1].$$

Agregamos:

$$s_f^{\text{rule}}(a) = \text{agg}(r_{f,1}(a), \dots, r_{f,K_f}(a)),$$

donde agg puede ser una media ponderada, máximo, o función lógica difusa.

3.3. Componente de grafo / propagación

Construimos un grafo de conocimiento $G = (V, E)$ donde los nodos V incluyen argumentos a , premisas p , evidencias e , y fuentes u . Definimos una puntuación inicial s_v^0 para cada nodo v (por ejemplo, $s_a^0 = s_f^{\text{ML}}(a)$ para nodos a). Se realiza propagación de etiquetas mediante minimización de energía (label propagation):

$$\min_{\{s_v\}_{v \in V}} \sum_{v \in V} \alpha_v (s_v - s_v^0)^2 + \sum_{(v,w) \in E} \beta_{vw} (s_v - s_w)^2,$$

donde $\alpha_v > 0$ y $\beta_{vw} \geq 0$ son pesos (ej.: $\beta_{(a,p)}$ mayor si p es premisa fuerte de a). La solución tiene forma lineal y produce s_v^* , de la cual extraemos $g_f(a) := s_a^*$ como puntaje estructural para a y tipo f .

3.4. Combinación en un score final

Combinamos las tres fuentes de evidencia (ML, reglas, grafo) para obtener un *score* combinado por falacia:

$$S_f(a) = w_f^{\text{ML}} s_f^{\text{ML}}(a) + w_f^{\text{rule}} s_f^{\text{rule}}(a) + w_f^{\text{graph}} g_f(a),$$

con pesos $w_f \geq 0$ normalizados ($w_f^{\text{ML}} + w_f^{\text{rule}} + w_f^{\text{graph}} = 1$). Interpretamos

$$\Pr(Y_{a,f} = 1 \mid \mathcal{O}_a) \approx S_f(a).$$

4. Incorporación de la confiabilidad de evidencia y fuente

Sea $E_a = \bigcup_{p \in \text{Prem}(a)} E_p$ el conjunto de evidencias relacionadas con a . Definimos un factor de peso agregado:

$$W_{\text{evid}}(a) = \frac{1}{|E_a|} \sum_{e \in E_a} \text{rel}_e \cdot \text{cred}(u_e).$$

Ajustamos la contribución del componente basado en reglas y/o ML multiplicando por la función $\gamma(W_{\text{evid}}(a))$, donde $\gamma : [0, 1] \rightarrow (0, \infty)$ es monótona creciente; por ejemplo:

$$\gamma(w) = 1 + \eta w, \quad \eta \geq 0.$$

Entonces la combinación se modifica a

$$S_f(a) = \gamma(W_{\text{evid}}(a)) (w_f^{\text{ML}} s_f^{\text{ML}}(a) + w_f^{\text{rule}} s_f^{\text{rule}}(a)) + w_f^{\text{graph}} g_f(a).$$

5. Decisión y umbrales óptimos

Decidir que a contiene la falacia f corresponde a tomar la decisión $\hat{Y}_{a,f} = 1$ si $S_f(a) \geq \tau_f$ para cierto umbral $\tau_f \in (0, 1)$. Para elegir τ_f óptimo consideramos el maximizar la utilidad esperada por instancia:

Definimos utilidades:

$$U_{\text{TP},f} = \text{ganancia por verdadero positivo}, \quad U_{\text{FP},f} = -C_{\text{FP},f}, \quad U_{\text{FN},f} = -C_{\text{FN},f}.$$

La utilidad esperada al decidir $\hat{Y}_{a,f} = 1$ es:

$$\mathbb{E}[U \mid S_f(a)] = S_f(a) \cdot U_{\text{TP},f} + (1 - S_f(a)) \cdot U_{\text{FP},f}.$$

Al decidir $\hat{Y}_{a,f} = 0$:

$$\mathbb{E}[U \mid S_f(a)] = S_f(a) \cdot U_{\text{FN},f} + (1 - S_f(a)) \cdot U_{\text{TN},f}.$$

Comparando las dos cantidades, el umbral óptimo τ_f^* satisface:

$$\tau_f^* = \frac{U_{\text{TN},f} - U_{\text{FP},f}}{(U_{\text{TP},f} - U_{\text{FP},f}) - (U_{\text{FN},f} - U_{\text{TN},f})}.$$

En caso de simetría y $U_{\text{TN},f} = 0$, $U_{\text{TP},f} = 1$, $U_{\text{FP},f} = -c_{\text{fp}}$, $U_{\text{FN},f} = -c_{\text{fn}}$, la expresión simplifica y se puede computar numéricamente.

6. Entrenamiento: función de pérdida y regularización

Sea $\mathcal{D} = \{(a_i, y_{i,f})\}_{i=1}^N$ un conjunto anotado por expertos para la falacia f . Entrenamos parámetros θ_f (modelo ML) minimizando la pérdida logística ponderada con costos ajustados:

$$\mathcal{L}(\theta_f) = - \sum_{i=1}^N \left[\omega_{i,f}^+ y_{i,f} \log \sigma(\theta_f^\top \phi(a_i)) + \omega_{i,f}^- (1 - y_{i,f}) \log (1 - \sigma(\theta_f^\top \phi(a_i))) \right] + \frac{\lambda}{2} \|\theta_f\|^2.$$

Los pesos $\omega_{i,f}^+, \omega_{i,f}^-$ pueden codificar el costo diferencial de FP/FN o compensar desequilibrio de clases.

7. Regularización simbólica: honrar axiomas

Para integrar axiomas (por ejemplo, exclusividad entre tipos), podemos añadir penalizaciones suaves a la pérdida. Por ejemplo, si f_1 y f_2 son mutuamente excluyentes, añadimos:

$$\mathcal{R}_{\text{excl}} = \mu \sum_{i=1}^N S_{f_1}(a_i) S_{f_2}(a_i),$$

con $\mu > 0$, que penaliza puntuaciones altas simultáneas.

8. Modelo de propagación en grafo (detalles)

Sea A la matriz de adyacencia del grafo G . Denotamos por $\mathbf{s}^0 \in \mathbb{R}^{|V|}$ el vector de puntuaciones iniciales y por $\mathbf{s}$ el vector final. La energía a minimizar:

$$E(\mathbf{s}) = (\mathbf{s} - \mathbf{s}^0)^\top D_\alpha (\mathbf{s} - \mathbf{s}^0) + \mathbf{s}^\top L_\beta \mathbf{s},$$

donde $D_\alpha = \text{diag}(\alpha_v)$ y L_β es la Laplaciana ponderada $L_\beta = D_\beta - B$ con B la matriz simétrica de pesos β_{vw} y D_β su diagonal. La solución se obtiene resolviendo el sistema lineal:

$$(D_\alpha + L_\beta) \mathbf{s} = D_\alpha \mathbf{s}^0.$$

9. Control de recursos: selección de métodos bajo presupuesto

Disponemos de un conjunto de métodos $M = \{m\}$ (reglas baratas, ML, análisis semántico profundo, verificación externa) con coste cost_m y ganancia esperada de información $\text{IG}_m(a)$ por aplicar m a argumento a . Queremos escoger un subconjunto $S \subseteq M$ que maximice la ganancia esperada sujeta a un presupuesto B :

$$\begin{aligned} \max_{x_m \in \{0,1\}} \quad & \sum_{m \in M} x_m \cdot \sum_{a \in \mathcal{A}} \text{IG}_m(a) \\ \text{s.a.} \quad & \sum_{m \in M} x_m \cdot \text{cost}_m \leq B. \end{aligned}$$

Es un problema tipo knapsack binario; en la práctica se resuelve por heurística (greedy) o programación entera si el tamaño lo permite.

10. Métricas de evaluación

Dadas predicciones $\hat{Y}_{a,f} \in \{0, 1\}$ y etiquetas reales $Y_{a,f}$ en un conjunto de prueba:

$$\begin{aligned} \text{Precision}_f &= \frac{\sum_a \hat{Y}_{a,f} Y_{a,f}}{\sum_a \hat{Y}_{a,f}} \\ \text{Recall}_f &= \frac{\sum_a \hat{Y}_{a,f} Y_{a,f}}{\sum_a Y_{a,f}} \\ \text{F1}_f &= \frac{2 \text{Precision}_f \text{Recall}_f}{\text{Precision}_f + \text{Recall}_f} \end{aligned}$$

Además, definimos métricas de equidad (fairness) y calibración:

- **Calibration:** comparar $\Pr(Y_{a,f} = 1 \mid S_f(a) = s)$ con s en bandas.
- **AUC_f** para evaluar ranking por probabilidad.
- **Costo esperado:**

$$\mathbb{E}[\text{Costo}] = \sum_f \left(C_{\text{FN},f} \cdot \text{FN}_f + C_{\text{FP},f} \cdot \text{FP}_f \right).$$

11. Tratamiento de premisas implícitas

Las premisas implícitas (no expresadas) se modelan como variables latentes z_p^{impl} que pueden inferirse mediante modelos de lenguaje/heurísticas. Podemos añadirlas en el vector de features $\phi(a)$ como $\phi_{\text{impl}}(a) = \mathbb{E}[z_p^{\text{impl}} \mid \text{Conc}(a), \text{Prem}(a)]$ y actualizar $s_f^{\text{ML}}(a)$ en consecuencia.

12. Ejemplo resumido del pipeline de inferencia (en forma matemática)

Para cada $a \in \mathcal{A}$:

1. Extraer $\phi(a)$, E_a y $W_{\text{evid}}(a)$.
2. Calcular $s_f^{\text{ML}}(a) = \sigma(\theta_f^\top \phi(a))$ para cada f .
3. Evaluar reglas $r_{f,k}(a)$ y agregar $s_f^{\text{rule}}(a)$.
4. Construir/actualizar G y computar $g_f(a)$ por propagación.
5. Combinar: $S_f(a) = \gamma(W_{\text{evid}}(a))(w_f^{\text{ML}} s_f^{\text{ML}}(a) + w_f^{\text{rule}} s_f^{\text{rule}}(a)) + w_f^{\text{graph}} g_f(a)$.
6. Tomar decisión $\hat{Y}_{a,f} = \mathbf{1}\{S_f(a) \geq \tau_f\}$ con $\tau_f = \tau_f^*$ (óptimo por utilidad) o umbrales calibrados según métricas.

13. Integración con axiomas lógicos (SWRL / penalizaciones)

Para axiomas lógicos estrictos (p. ej. exclusividad), si deseas imponerlos como constraints duras, se puede forzar $\hat{Y}_{a,f_1} + \hat{Y}_{a,f_2} \leq 1$ para pares excluyentes. Si se prefiere suavizar, usar

$\mathcal{R}_{\text{excl}}$ en la pérdida como se indicó.

14. Resumen de parámetros a estimar y datos necesarios

- Parámetros ML: $\{\theta_f\}_{f \in \mathcal{F}}$.
- Pesos de combinación: $\{w_f\}_f$.
- Pesos de propagación: $\{\alpha_v, \beta_{vw}\}$.
- Umbrales $\{\tau_f\}$ (ó directamente matrices de utilidad).
- Datos: corpus anotado por tipo de falacia/sesgo, metadatos de fuentes (credibilidad), evidencias con fiabilidad.

15. Notas prácticas y recomendaciones

1. Empieza con un prototipo simple: pocas falacias, reglas bien definidas, logistic baseline.
2. Añade grafo y propagación cuando exista estructura de relaciones (citas, premisas compartidas).
3. Calibra probabilidades (Platt / isotonic) y ajusta umbrales por costos reales (evitar alarmas innecesarias).
4. Mantén trazabilidad: cada decisión $\hat{Y}_{a,f}$ debe producir explicación basada en reglas y en evidencia ponderada.

16. Conclusión

Este modelo matemático integra tu ontología y axiomas en un marco híbrido (simbólico + probabilístico + grafo) con decisiones óptimas basadas en utilidad y control de recursos. Si quieres, puedo:

- Generar el **formato concreto** de salida JSON para $\hat{Y}$ y explicación.
- Producir ejemplos numéricos y un pequeño conjunto sintético de entrenamiento.
- Traducir las reglas simbólicas a SWRL/Drools automáticamente (reglas concretas).